

CIENCIA DE DATOS (TA047)

Cátedra Dr. Ing. Rodríguez - 1°C 2025

Trabajo práctico 1 – Grupo 3

Ejercicio 1: *Análisis Exploratorio de Datos*

Integrantes:

- **Arias Rafaela Pilar**, Padrón: 112272,
Email: rparias@fi.uba.ar.
- **Barcala Roca Ramiro**, Padrón: 112478,
Email: rbarcala@fi.uba.ar.
- **lenco, Lara Eliana**, Padrón: 111921,
Email: lienco@fi.uba.ar.
- **Lema Mora**, Padrón: 111831,
Email: molema@fi.uba.ar.

Fecha de entrega: 01/05/25

Ejercicio 1: Análisis exploratorio

Introducción a la organización del trabajo

Optamos por vincular Colab con nuestro repositorio de Github y creamos un servidor de Discord para poder comunicarnos más cómodamente. Hicimos llamadas regularmente para ayudarnos entre nosotros, trabajar en conjunto y debatir distintas ideas para el trabajo. Además, creamos una hoja de [Excel](#) para la división de tareas y una [planilla](#) con las funciones vistas en clase.

Breve descripción y análisis del dataset

Meses asignados: Julio / Agosto / Septiembre.

El Dataset contiene información sobre los viajes de los Taxis amarillos de Nueva York. Inicialmente la información estaba dividida por mes en archivos de formato .parquet, pero decidimos unirla en un mismo DataFrame concatenando por filas. Finalmente, la cantidad de registros inicial fue de 9.689.116 y la cantidad de columnas inicial fue 19.

El siguiente paso fue establecer qué tipo de variable era cada columna. Las dividimos en Cuantitativas y Cualitativas, que a su vez clasificamos en continuas y discretas y en nominales y ordinales, respectivamente. El criterio establecido para esta clasificación fue el propuesto por los apuntes de la materia¹, aunque también consultamos fuentes externas². Además, en el Colab traducimos el [Data Dictionary – Yellow Taxi Trip Records](#) proporcionado por la cátedra para comprender mejor qué significaba cada columna. La división final fue la siguiente:

¹ Sin autor. (2025, marzo 25). Tipos de variables. FIUBA, Cátedra Dr. Ing. Rodríguez. Recuperado de: https://docs.google.com/document/d/1e8hDYVVx1PZScIsttjIGGE0Bci1reZH8kFx8CyHPgl4/edit?usp=drive_link

² Julca, J. E. (2025, febrero 22). Tipos de variables estadísticas: Cuantitativas y Cualitativas. Escuela de Investigación. Recuperado de: <https://escueladeinvestigacion.com/2025/02/22/tipos-de-variables-estadisticas-cuantitativas-y-cualitativas/>

Sin autor. (2022, junio 7). ¿Qué es una variable discreta? (ejemplos). Probabilidad y estadística. Recuperado de: <https://www.probabilidadyestadistica.net/variable-discreta/>

Tipo de variable	Cuantitativas	Tipo de variable	Cualitativas
Continua	tpep_pickup_datetime, tpep_dropoff_datetime, trip_distance, fare_amount, extra, mta_tax, tip_amount, tolls_amount, total_amount, congestion_surcharge.	Nominal	VendorID, store_and_fwd_flag, PULocationID, DOLocationID, payment_type, RatecodeID
Discreta	passenger_count, improvement_surcharge, Airport_fee	Ordinal	—

En particular:

Cuantitativas

Para establecer qué variables pertenecían a la categoría de cuantitativas, tomamos la definición propuesta por la cátedra: “...entre dos valores de la variable existen infinitos valores intermedios...”

- **tpep_pickup_datetime:** La fecha y hora en que el taxímetro fue activado. **Tipo:** cuantitativa **continua**, ya que, al ser una fecha representa una medición en el tiempo que puede tomar infinitos valores dentro de un rango.
- **tpep_dropoff_datetime:** La fecha y hora en el que el taxímetro fue desactivado. **Tipo:** cuantitativa **continua**, ya que, al ser una fecha representa una medición en el tiempo que puede tomar infinitos valores dentro de un rango.
- **passenger_count:** El número de pasajeros en el vehículo, es un valor ingresado por el conductor. **Tipo:** cuantitativa **discreta** porque representa una cantidad que es contable y solo puede tomar valores enteros.
- **trip_distance:** La distancia del viaje transcurrida en millas reportada por el taxímetro. **Tipo:** cuantitativa **continua** representa una medición de distancia (en millas), y puede tomar infinitos valores dentro de un intervalo.
- **fare_amount:** La tarifa calculada por el taxímetro basada en el tiempo y la distancia. **Tipo:** cuantitativa **continua** porque representa dinero y admite decimales entre dos valores.
- **extra:** Extras y recargos varios. Actualmente, esto solo incluye los recargos de USD 0.50 y USD 1 por hora punta y durante la noche. **Tipo:** cuantitativa

continua porque el recargo se va sumando, lo que genera que dentro de extra haya números no enteros y no hay un rango que la limite.

- **mta_tax:** Impuesto MTA de USD 0.50 que se activa automáticamente según la tarifa del taxímetro en uso. **Tipo:** cuantitativa **discreta** porque este impuesto es fijo: solo 0.50 o, si no se aplica, 0.
- **tip_amount:** Monto de la propina. Este campo se completa automáticamente para las propinas pagadas con tarjeta de crédito. Las propinas en efectivo no están incluidas. **Tipo:** cuantitativa **continua** ya que no hay un rango que pueda limitarla y porque representa dinero y admite decimales entre dos valores.
- **tolls_amount:** Monto total de todos los peajes pagados durante el viaje. **Tipo:** cuantitativa **continua** porque, al representar el monto total de peajes, puede contener números decimales y no se encuentra dentro de un rango establecido.
- **improvement_surcharge:** Recarga de mejora de USD 0.30 aplicado a los viajes al momento de iniciar el viaje (flag drop). **Tipo:** cuantitativa **discreta**, ya que se posee dos alternativas: o son 0.30 o 0.
- **total_amount:** El monto total cobrado a los pasajeros. No incluye las propinas en efectivo. **Tipo:** cuantitativa **continua** porque no tiene un rango establecido y no es contable, ya que el total puede tener decimales.
- **congestion_surcharge:** Monto total recaudado en el viaje por el recargo por congestión de NYS (Estado de Nueva York). **Tipo:** cuantitativa **discreta**, ya que, por cómo fue establecido el impuesto, se cobra 0.50 a los viajes grupales o 2.5 en cada viaje con taxi amarillo. Y si no se aplica es 0.
- **Airport_fee:** USD 1.25 sólo por la recogida en los aeropuertos de LaGuardia y John F. Kennedy. **Tipo:** cuantitativa **discreta**, pues toma el valor de 1.25 cuando se recoge en esos aeropuertos o sino vale 0.

Cualitativas

Nuevamente optamos por utilizar la definición propuesta por la cátedra para establecer qué variables correspondían a esta categoría: “...se distinguen por ser diferentes, no se puede establecer un ordenamiento entre ellas...”

- **VendorID:** Un código que indica el proveedor de TPEP (Taxi and Limousine Commission's Taxi Passenger Enhancement Program) que proporcionó el registro. 1 = *Creative Mobile Technologies, LLC*; 2 = *VeriFone*. **Tipo:** cualitativa **numérica nominal** ya que cada número representa una categoría sin orden ni jerarquía específica.
- **RatecodeID:** El código final de tarifa en vigor al final del viaje. 1 = *Tarifa estándar*; 2 = *JFK*; 3 = *Newark*; 4 = *Nassau o Westchester*; 5 = *Tarifa negociada*; 6 = *Viaje en grupo*. **Tipo:** cualitativa **numérica nominal** ya que cada número representa una categoría sin orden ni jerarquía específica.

- **store_and_fwd_flag:** Un indicador que señala si el registro del viaje fue guardado en la memoria del vehículo antes de ser enviado al proveedor, también conocido como 'almacenar y reenviar', porque el vehículo no tenía conexión al servidor. *Y = viaje almacenado y reenviado; N = no es un viaje almacenado y reenviado.* **Tipo:** cualitativa **texto nominal**, ya que “Y” o “N” no tienen jerarquía ni orden entre sí.
- **PULocationID:** Zona de taxi de la TLC (Comisión de Taxis y Limusinas) en la que se activó el taxímetro. **Tipo:** cualitativa **numérica nominal** ya que los números identifican zonas específicas, pero no implican cantidad ni orden.
- **DOLocationID:** Zona de taxi de la TLC en la que se desactivó el taxímetro. **Tipo:** cualitativa **numérica nominal** ya que los números identifican zonas específicas, pero no implican cantidad ni orden.
- **payment_type:** Un código numérico que indica cómo el pasajero pagó el viaje. *1 = Tarjeta de crédito; 2 = Efectivo; 3 = Sin cargo; 4 = Disputa; 5 = Desconocido; 6 = Viaje.* **Tipo:** cualitativa **numérica nominal** ya que cada número representa una categoría sin orden ni jerarquía específica.

Los features más destacables para nosotros fueron **total_amount**, **payment_type**, **passenger_count**, **trip_distance** y **tip_amount**. Consideramos que estas variables brindan una gran cantidad de información sobre cada viaje, ya que permiten conocer lo que costó y cómo se pagó, cuántas personas viajaron (y consecuentemente pagaron), la distancia recorrida y la propina dejada.

Otras variables que nos interesaron fueron **tpep_pickup_datetime** y **tpep_dropoff_datetime**, ya que permiten conocer la duración de los viajes y **PULocationID** y **DOLocationID** porque permiten conocer el lugar donde se inició o terminó un viaje, respectivamente. Estas últimas cuatro que mencionamos (por más interesantes que nos hayan resultado) no son las principales, y solemos utilizarlas en relación con otras variables (más adelante se detallarán).

Supuestos e hipótesis

- A mayor cantidad de pasajeros, más costoso el viaje.
- Los viajes más largos se hacen en hora pico (6:00 a 8:00 AM/PM), viéndose representado como la personas desplazándose hacia su lugar de trabajo.
- En la llegada de estaciones de los barrios más pudientes, la propina es mayor.
- A mayor distancia recorrida, mayor propina.
- A mayor distancia recorrida, mayor cobro en peajes.

Análisis más profundo de los registros

Datos faltantes y eliminación de columnas

Con respecto a la eliminación de columnas, primero analizamos los datos faltantes en el dataset. El análisis concluyó en que cada una de las siguientes variables tiene 1021387 faltantes (10.542%): **RatecodeID**, **Airport_fee**, **congestion_surcharge**, **passenger_count**, **store_and_fwd_flag**.

RatecodeID tiene como valores posibles números del 1 al 6 que indican un tipo de tarifa específico. Para recuperar algunos de esos datos faltantes, analizamos los tipos de tarifas y llegamos a la conclusión de que podíamos recuperar las correspondientes a los números 2, 3 y 4. Esto se debió a que el 2 (Tarifa JFK) se aplica cuando la recogida o la dejada fue en el Aeropuerto JFK, por lo que, si el PULocationID o el DOLocationID eran los correspondientes al aeropuerto, podíamos reemplazar el NaN. Lo mismo sucedió con 3 (Tarifa Newark), que es desde/hacia el Aeropuerto de Newark y con 4 (Tarifa Nassau o Westchester), que queda fuera de Nueva York. Todas las IDs correspondientes a la zona del aeropuerto de JFK, Newark y Nassau o Westchester fueron obtenidas del archivo [taxi_zone_lookup](#), que es un archivo csv que contiene la ID, el barrio, la zona y la zona de servicio de los viajes en taxi.

En el caso de **Airport_fee**, se aplicaba el impuesto de 1.25 USD si los viajes comenzaron en los aeropuertos de La Guardia y JFK, por lo que procedimos de una forma similar al RatecodeID: nos aseguramos de tener las IDs correspondientes a cada aeropuerto y si el viaje comenzaba en ellos (o sea si la PULocationID concordaba) se asignaba el 1.25, sino 0.

Con la variable **congestion_surcharge** necesitamos investigar un poco más del impuesto, por lo que visitamos la página de [Taxi & Limousine de Nueva York](#) y la página del [Departamento de Impuestos de Nueva York](#). En resumen, el impuesto es un recargo obligatorio por congestión vehicular que se aplica en Manhattan al sur de la calle 96th Street, implementado a partir de enero de 2019. El monto del recargo depende del tipo de vehículo que se utilice para el transporte en o a través de la zona de congestionamiento. El recargo generalmente es \$2.50 por cada viaje cuando el transporte sea en taxi amarillo y \$0.75 por cada viaje compartido. Tras investigar, agrupamos las distintas zonas de [taxi_zone_lookup](#), filtrando solo las que estaban al sur de la calle 96th Street. Obtuvimos sus IDs y buscamos si había viajes en grupo con NaN por esas zonas. Como no había, no reemplazamos nada y seguimos con los viajes en taxi amarillo por esas zonas, reemplazando los NaN con 2.5.

Respecto a la variable **passenger_count**, observamos que los valores oscilan entre 0 y 9. Para los casos con valores faltantes (NaN), así como para

aquellos registros con 0 o 6 pasajeros (considerando que el máximo permitido en los taxis de Nueva York es de 5 personas) decidimos imputarlos con la moda de la variable. Por otro lado, eliminamos los registros con valores entre 7 y 9, ya que los consideramos atípicos: no sólo es físicamente imposible transportar esa cantidad de personas en un taxi, sino que también es ilegal. Además, la cantidad de registros con estas cifras era muy baja (menos de 40).

Por último, en el caso de **store_and_fwd_flag**, primero queríamos ver su relación con la variable **trip_distance**, ya que pensamos que los viajes más largos tenían más probabilidades de tener **store_and_fwd_flag** nulo, lo cual es coherente con la idea de que los viajes largos podrían verse afectados por falta de conexión durante el recorrido, lo que provoca que el registro se guarde y luego se reenvíe. Pero luego, observamos que los porcentajes de nulos varían de manera significativa según el tramo de distancia, y parece que no existe un patrón claro ni constante para poder sustituir los valores nulos. Por lo que optamos por eliminar los datos nulos de la variable.

Correlación y covarianza

En el análisis de covarianza, no encontramos valores significativamente altos en la mayoría de las variables. Sin embargo, se observó una relación destacada entre las variables **fare_amount** y **total_amount**, lo cual coincide con el análisis de correlación que se realizará más adelante. Este hallazgo tiene sentido, dado que ambas variables están estrechamente relacionadas, siendo la suma de varios cargos que componen el costo total del viaje.

Por otro lado, no surgieron otros valores de covarianza de interés. En el caso de las variables **PULocation** y **DOLocation**, la covarianza no aportó información relevante, ya que se trata de variables cualitativas que no se pueden analizar en este tipo de contexto de manera directa.

En la **matriz de correlación** encontramos valores altos en:

- **fare_amount y total_amount**: Esta relación es probablemente la más intuitiva, ya que, en general, a mayor tarifa base del viaje, mayor será el monto total que paga el pasajero (incluye impuestos, propinas, peajes, entre otros cargos).
- **tip_amount y total_amount**: También es una relación predecible. A medida que el viaje se vuelve más largo o costoso, es más probable que el conductor reciba una mejor propina.

- **mta_tax y improvement_surcharge:** Esta fue la relación más inusual. Aunque ambas variables son teóricamente discretas y tienden a tomar valores fijos, la presencia de outliers afectó la distribución, reduciendo ligeramente la fuerza de la relación esperada.

Además, aprovechamos esta etapa del análisis para descartar varios de los supuestos iniciales que habíamos planteado. Más adelante detallaremos los motivos de cada descarte.

Generación de nuevos features

Decidimos, con los datos ya existentes, crear los siguientes features:

Features de Imaginación

- **trip_duration:** Consideramos importante incorporar este feature, ya que es una de las pocas variables del tipo cuantitativo numérico. Resulta útil para conocer la duración de cada viaje, identificar la duración mínima dentro de un grupo de viajes o realizar distintos tipos de análisis relacionados.

Features de discretización

- **month:** Nos permite agrupar los viajes según los tres meses en los que ocurrieron. Esto resulta útil ya que, originalmente, los datasets venían separados por mes, pero los unimos por conveniencia. Esta variable nos da la posibilidad de volver a analizarlos por separado si es necesario.
- **day_of_the_week:** Permite agrupar los viajes por día de la semana, lo cual es útil para analizar patrones como los métodos de pago más utilizados en determinados días.
- **bins_trip_distance:** Agrupa los viajes en rangos fijos de distancia. Esto facilita filtrar rápidamente, por ejemplo, los viajes cortos, y enfocarse en ellos para ciertos análisis.
- **rush_hour:** Es una variable booleana que indica si el viaje ocurrió en horario pico. Es útil para dividir los datos entre viajes en hora pico y los que no, y así poder analizar ambos grupos por separado.

Consideramos generar más features basadas en discretización, especialmente sobre montos de dinero, pero resultó ser una tarea más abstracta. ¿Quién define qué es barato o caro? Con las distancias ocurría algo similar aunque en menor medida (ya que las distancias son objetivas, mientras que los sueldos y percepciones de costo varían entre personas). Por eso optamos por discretizar distancias en lugar de montos.

No se crearon features de normalización. Consideramos que no era relevante en este caso, ya que la mayoría de las variables cuantitativas comparten una característica común: no toman valores negativos. En este contexto, la normalización pierde utilidad, dado que ya sabemos de antemano que los valores son necesariamente positivos, y su escala no representaba un problema para los análisis que realizamos.

Valores atípicos

Con el objetivo de preservar la mayor cantidad posible de información sin comprometer la calidad de los datos, analizamos cuidadosamente los valores atípicos presentes en distintas variables del conjunto de datos. En cada caso, se decidió entre eliminar o imputar los valores extremos en función de su severidad, frecuencia y grado de razonabilidad dentro del contexto del problema.

1. trip_distance

Para esta variable, se utilizó el método de Z-score para detectar valores atípicos:

- Se eliminaron los valores **extremadamente atípicos**, es decir, aquellos con un Z-score mayor a 4. Primero se analizó con un umbral de decisión igual a 3 pero de este modo quedaban demasiados valores marcados como atípicos a pesar de que eran valores con mucha probabilidad de ocurrir, no salían de lo “lógico”, por lo tanto decidimos incrementar el umbral para ver realmente cuales eran los valores más extremos. Un ejemplo a destacar que nos causó asombro y gracia fue que había un viaje que recorrió 330.397,59 millas, cuando una vuelta al mundo son 24,901 millas. Lo que le agrega un toque especial es que, además, se supone que recorrió esa distancia en el rango de 3 meses que nos fue asignado. Investigando más, descubrimos que el viaje duró 14 minutos (pues el tpep_pickup_datetime y tpep_dropoff_datetime son la misma fecha pero con 14 minutos de diferencia...)

```
fila_max_distancia = data[data['trip_distance'] == data['trip_distance'].max()]  
fila_max_distancia
```

VendorID	tpep_pickup_datetime	tpep_dropoff_datetime	passenger_count	trip_distance	
9434826	2	2024-09-15 14:18:00	2024-09-15 14:32:00	NaN	330397.590000

- Para los valores **moderadamente atípicos** (Z-score entre 3 y 4), se aplicó una **imputación con la mediana** de la variable, considerando que estos pueden deberse a errores de medición menores o situaciones poco frecuentes, pero no imposibles.

2. fare_amount

Para esta variable se eliminaron los valores mayores a **250**, ya que se consideran extremadamente atípicos para una tarifa de taxi. Los valores restantes que superaban levemente ese umbral fueron **imputados con la mediana**, conservando la tendencia general de la variable.

3. tip_amount

Respecto a esta variable, se eliminaron los valores mayores a **200**, por considerarse poco realistas como propina. Los valores atípicos menos extremos fueron **imputados con la mediana**, manteniendo la distribución general sin perder demasiada información.

4. tolls_amount

Con relación a esta variable, se eliminaron los valores mayores a **150**, considerados anómalos en el contexto de peajes en la ciudad. Los valores moderadamente altos fueron **imputados con la mediana**, utilizando el mismo criterio que en las variables anteriores.

5. passenger_count

Sobre `passenger_count`, se identificó que los valores válidos para la variable `passenger_count` se encuentran entre **1 y 5**, que es el rango permitido para los taxis de Nueva York. Se **imputaron con la moda** aquellos registros que presentaban valores faltantes (NaN), o que tenían valores 0 o 6, los cuales se consideran inconsistentes o inusuales. Los registros con valores entre **7 y 9** fueron **eliminados**, ya que representan situaciones físicamente imposibles o ilegales, y además eran muy poco frecuentes.

6. total_amount


Acerca de total_amount, se eliminaron los registros con un total_amount mayor a **800**, ya que representaban montos excesivos e improbables para un viaje típico. Adicionalmente, se verificó la **coherencia interna** de esta variable. Se comparó el valor de total_amount con la suma de sus componentes (fare_amount, extra, tip_amount y tolls_amount). Si la diferencia era mayor a una **tolerancia de 1 unidad**, y el valor no era extremo, se consideró **incoherente** y se **imputó con la media** de la variable.

Preguntas de investigación

En base a todo el análisis previo y considerando el Dataset, planteamos una serie de preguntas.

1. **¿Qué estaciones de taxi son las más frecuentadas? ¿Cuántos viajes se realizan en las zonas más céntricas de la ciudad?**

Estaciones de Taxi mas frecuentadas en NYC




El gráfico tipo *treemap* muestra claramente que las estaciones de taxi más utilizadas se encuentran en **Manhattan**, particularmente en zonas como **Midtown Center**, **Upper East Side North**, **Murray Hill**, y **Times Sq/Theatre District**. Estas áreas están entre las más céntricas, comerciales y densamente pobladas de la ciudad.

Además, se observa que los aeropuertos, especialmente **JFK Airport** y **LaGuardia Airport** en Queens, también concentran una alta cantidad de viajes, lo que es esperable dada la necesidad frecuente de transporte desde y hacia estos puntos.

Podemos concluir que **la mayoría de los viajes en taxi se concentran en las zonas más céntricas y activas de la ciudad**, como Manhattan, donde hay una mayor demanda por motivos laborales, turísticos y de conectividad urbana.


2. ¿En qué estaciones se suben más personas durante la hora pico?

Zonas con más recogidas en hora pico (18:00)



Durante la hora pico de las 18:00, las zonas que registran más recogidas de pasajeros en la ciudad de Nueva York son principalmente las áreas **más céntricas de Manhattan**. Estas zonas se caracterizan por su alta densidad residencial y comercial, lo cual genera una mayor demanda de taxis al finalizar la jornada laboral.



3. ¿Hay algún mes en particular que tenga mayor recaudación?



Según el gráfico, el mes con mayor recaudación es **septiembre**, con un total superior a los 90 millones de dólares (US\$), seguido por **julio**, con una recaudación cercana a los 80 millones y luego por **agosto**, con una leve disminución respecto a julio, quedando como el mes con menor recaudación entre los tres.

Esto sugiere un aumento significativo en la actividad o en las tarifas durante septiembre, lo que podría estar relacionado con el regreso de la actividad laboral o escolar después del verano.

4. ¿Qué método de pago eligen más los pasajeros? ¿Cuánto recaudó cada método de pago?




El método de pago más utilizado por los pasajeros es **la tarjeta de crédito**, representando el **86.98%** del total recaudado. Esto indica una clara preferencia por medios electrónicos a la hora de abonar los viajes, lo que puede deberse a factores como comodidad, seguridad, o políticas de incentivo por parte del servicio. La baja participación del pago en efectivo sugiere una tendencia hacia la digitalización de las transacciones en este ámbito.

Además, al incorporar la nueva feature (`day_of_the_week`) que indica el día de la semana, fue posible graficar esta información y analizarla en relación con la cantidad de viajes y el método de pago utilizado. Este gráfico nos permitió responder dos preguntas clave:

5. ¿Qué estaciones de taxi se llevan la mayor cantidad del total de la propina?

Esta pregunta se relaciona con uno de los supuestos que planteamos, por lo que profundizaremos en ella más adelante con su gráfico correspondiente.

6. ¿Cuál es la variación de elección de métodos de pago en base al día de la semana? ¿Hay diferencias significativas entre días laborables y fines de semana en el uso de métodos de pago?



A partir del análisis visual, observamos que los jueves son el día con mayor cantidad de viajes, mientras que los domingos presentan una disminución notable. Además, no se evidencian patrones distintos en la elección de métodos de pago a lo largo de la semana, por lo general predomina el medio de pago tarjeta de crédito por sobre el efectivo.

Supuestos

– Supuestos Descartados


Durante el análisis inicial, planteamos algunas hipótesis intuitivas sobre la relación entre ciertas variables. Sin embargo, al evaluar la correlación entre ellas, observamos que no existía una relación lineal significativa. Dado que la correlación es una condición necesaria para investigar posibles relaciones de causalidad, decidimos descartar estos supuestos:

- **"A mayor cantidad de pasajeros, mayor costo del viaje"**: La correlación entre `passenger_count` y `total_amount` tiende a 0, por lo que no se evidencia una relación clara entre estas variables.
- **"A mayor distancia, mayor cobro en peajes"**: Al analizar la relación entre `trip_distance` y `tolls_amount`, también encontramos una correlación cercana a 0, descartando este supuesto.
- **"A mayor distancia recorrida, mayor propina"**: En este caso, la correlación entre `trip_distance` y `tip_amount` fue nula o muy baja, por lo que tampoco se justifica seguir profundizando esta hipótesis.

En resumen, en los tres casos se concluyó que, al no cumplirse una condición de correlación alta, no había fundamento suficiente para investigar una posible relación causal.

– Supuesto confirmados

Planteamos la hipótesis de que **"los viajes más largos tienden a realizarse durante las horas pico (6:00 a 8:00 AM/PM)"**, como reflejo del desplazamiento de las personas hacia o desde sus lugares de trabajo. Para responder esta pregunta, realizamos un análisis visual a través de un gráfico que mostraba la duración de los viajes segmentada por franja horaria.




Los resultados indicaron que efectivamente, hay un aumento en la cantidad de viajes largos durante las horas pico, especialmente en el rango de la tarde. Sin embargo, la diferencia no fue abismal: en promedio, la cantidad de viajes largos durante esas franjas horarias fue aproximadamente tres veces mayor que en otros momentos del día.

Dado esto, podríamos atribuir el fenómeno más a una cuestión de demanda general de taxis en esas horas específicas que a una relación directa con la longitud del viaje. Aun así, y considerando la evidencia observada, confirmamos este supuesto. **¿Las propinas son mayores al llegar a estaciones ubicadas en barrios más pudientes?**

Esta hipótesis apuntaba a identificar si existe una relación entre el nivel socioeconómico de las zonas de destino y el monto de propina entregado al conductor. Para evaluarla, realizamos un gráfico tipo *treemap* en el que representamos la suma total de propinas recibidas, agrupadas por estaciones de llegada.

El análisis confirmó nuestra suposición: **las estaciones ubicadas en barrios más pudientes concentran un mayor monto acumulado en propinas**. Esto sugiere que los pasajeros que viajan hacia esas zonas, en promedio, tienden a dejar mejores propinas, lo cual podría estar relacionado con su poder adquisitivo o con prácticas culturales asociadas al uso del servicio.

Viendo ambos gráficos, nos daremos cuenta que parecería ser así (tomando como barrios pudientes aquellos que tengan valores altos de renta³, por ej)



Referencia a la imagen en pie de página³

Cuadro de tiempo dedicado

Para el Ejercicio 1 específicamente, trabajamos mucho juntos en llamada. Debatimos varios temas, ya que el análisis propuesto para este ejercicio fue exhaustivo.

Integrante	Tarea	Prom. Hs Semana
Ramiro Barcala Roca	Planteo y refutación de supuestos. Análisis de covarianza y correlación Creación de nuevos features Armado del Reporte Armado de gráficos	8

³ amNY News. (2021, noviembre 18). New heat map shows which areas of Manhattan are the most expensive to rent in. *Am New York*. Recuperado de: <https://www.amny.com/news/new-heat-map-shows-which-areas-of-manhattan-are-the-most-expensive-to-live-in/>

Rafaela Pilar Arias	Análisis inicial del Dataset Análisis e imputación de datos faltantes Creación de nuevos features Armado del Reporte Armado de gráficos	8
Mora Lema	Análisis e imputación de datos faltantes Análisis de outliers Armado del Reporte Armado de gráficos	8
Lara Eliana Ienco	Análisis inicial de los datos faltantes Creación de nuevos features Armado de gráficos	8