

CIENCIA DE DATOS (TA047)

Cátedra Dr. Ing. Rodríguez - 1°C 2025

Trabajo práctico 1 – Grupo 3

Ejercicio 4: Clustering

Integrantes:

- **Arias Rafaela Pilar**, Padrón: 112272,
Email: rparias@fi.uba.ar
- **Barcala Roca Ramiro**, Padrón: 112478,
Email: rbarcala@fi.uba.ar
- **lenco, Lara Eliana**, Padrón: 111921,
Email: liencho@fi.uba.ar
- **Lema Mora**, Padrón: 111831,
Email: molema@fi.uba.ar

Fecha de entrega: 01/05/25

Ejercicio 4: Clustering

Breve descripción y análisis del dataset

El dataset contiene datos de canciones (tracks) de Spotify. El objetivo es analizar si es posible agrupar los datos de un conjunto de datos en función de algún criterio, mediante el algoritmo K-Means. La cantidad de registros inicial del Dataset fue de 750 filas y 13 columnas.

Como es costumbre, realizamos un breve análisis del Dataset categorizando las columnas en cuantitativas y cualitativas:


Tipo de variable	Cuantitativas	Tipo de variable	Cualitativas
Continua	acousticness, danceability, duration, energy, instrumentalness, liveness, loudness, speechiness, tempo, valence	Nominal	mode
Discreta	time_signature	Ordinal	key

Tras haberlas categorizado, continuamos con el análisis examinando sus medidas de resumen, frecuencias y los posibles valores que pueden tomar. Luego analizamos los datos faltantes, pero al revisar el dataset descubrimos que no había ninguno. Por lo tanto, no fue necesario imputar valores y procedimos directamente al análisis de outliers.


Primero realizamos boxplots para hacer un análisis visual antes de aplicar métodos como el rango intercuartílico (IQR) y la puntuación Z-Score. Al observarlos, notamos que no había valores atípicos especialmente llamativos: en general, los valores identificados como outliers por los boxplots resultaban ser posibles y razonables. El único caso debatible fue el de la variable duration (duración en milisegundos de la canción), donde se observaron pistas con duraciones entre 400.000 y 700.000 ms, equivalentes a aproximadamente 6.67 y 11.67 minutos, respectivamente. Sin embargo, consideramos que estos valores son perfectamente posibles en el contexto musical y no lo suficientemente extremos como para justificar su eliminación o imputación. Quizás si hubieran superado los 15, 20 o 30 minutos, habríamos considerado intervenir.

Análisis de la tendencia al clustering

Una vez finalizado el análisis exploratorio, pasamos al objetivo principal del ejercicio: el clustering. Como primer paso, realizamos un Análisis de Componentes Principales (PCA) con el fin de explorar posibles agrupamientos lineales en los datos. Sin embargo, este análisis no arrojó resultados concluyentes, ya que la proyección en las primeras componentes principales no evidenciaba una separación clara entre grupos.




Dado este resultado, optamos por una alternativa no lineal: *t-Distributed Stochastic Neighbor Embedding* (t-SNE). Utilizamos un pipeline para asegurarnos de normalizar adecuadamente los datos antes de aplicar el algoritmo. Tras su implementación, notamos una diferencia considerable con respecto a PCA:



Notamos que la representación resultante mostraba agrupamientos mucho más definidos y visualmente distinguibles, lo que facilitó la identificación de posibles clusters. Con esto en mente, aplicamos el K-Means para hallar los distintos clusters. Probamos con K tomando los valores entre 2 y 10 (inclusivos) mediante el método del Codo y Silhouette. El método del Codo sugirió que 4 era una buena cantidad de grupos. Por este motivo, procedimos a aplicar el algoritmo K-Means con tres valores distintos de k: 2 (como elección aleatoria), 4 (por ser el valor sugerido por el método del codo) y 10 (por representar una de las opciones menos recomendadas, utilizada con fines comparativos). Luego analizamos los gráficos resultantes de cada agrupación para entender cómo se comportaban los datos bajo diferentes configuraciones.

Además, incorporamos las asignaciones de cluster como nuevas columnas en el dataset, lo que hizo que pasara de tener 13 a 16 columnas. Para visualizar los resultados, proyectamos cada una de las agrupaciones sobre el espacio reducido por PCA, y notamos que la opción con $k = 2$ resultaba particularmente interesante, ya que mostraba una mejor adecuación a la estructura de los datos en comparación con las demás alternativas.




Posteriormente, aplicamos el coeficiente de Silhouette para evaluar la calidad de los agrupamientos obtenidos. Este análisis indicó que la mejor opción era $k=2$, mientras que $k=6$ y $k=8$ obtuvieron el mismo puntaje como las siguientes mejores alternativas. Dado que la agrupación con $k = 10$ había sido incorporada únicamente como referencia y ninguno de los métodos utilizados la consideró adecuada, decidimos eliminar esa columna. En consecuencia, el dataset pasó de tener 16 a 15 columnas.

Con base en toda la información obtenida, decidimos establecer $k = 2$ como el valor óptimo, siguiendo lo indicado por el Silhouette Score. Este coeficiente mide qué tan cerca está un objeto de los demás en su propio cluster en comparación con objetos de otros clusters. Aunque la regla del codo sugería la posibilidad de contar con más clusters ($k = 4$), el análisis de Silhouette respalda la elección de $k = 2$ al obtener mejores métricas de calidad. Este valor permite una clara separación y agrupación de los datos, aspecto fundamental para su interpretación y análisis.

En resumen, consideramos que el número de clusters propuesto por Silhouette es el que realmente logra agrupar de forma coherente, ya que enfatiza la distancia entre clusters y la compacidad interna de los mismos, mientras que la regla del codo se basa únicamente en la inercia (la suma de las distancias cuadráticas dentro de los clusters). No estamos desestimando la utilidad del método del codo, sino que, en este caso, nuestra elección se apoya también en evidencias visuales obtenidas mediante t-SNE y PCA, que reflejaron de manera clara la estructura de los datos para $k = 2$.

Para analizar el agrupamiento utilizamos t-SNE para visualizar los clusters. Graficamos con los dos valores de k para sostener la elección de $k=2$.



Luego aplicamos la media a cada columna del Dataset y utilizamos la librería `tabulate` para visualizar el promedio de cada variable por cada cluster de forma más ordenada.

cluster_k=2	acousticness	danceability	duration	energy	instrumentalness	key	liveness	loudness	mode	speechiness	tempo	time_signature	valence
0	0.759425	0.466929	232094	0.29864	0.247272	4.36444	0.154536	-13.6362	0.826667	0.0500853	112.451	3.69778	0.366999
1	0.185095	0.651943	214978	0.720851	0.037233	5.02857	0.224308	-6.31212	0.704762	0.119915	123.815	3.99048	0.553174


Dada nuestra elección, establecimos que el número de grupos a formar debe ser 2. Estos grupos se caracterizan y dividen de la siguiente manera:


Cluster 0: Variables con valores altos: acousticness (0.76), instrumentalness (0.24) y duration (232094 ms, que equivale a 3.8682 minutos). Estos indican que los tracks agrupados en este cluster tienden a tener más instrumentales, con pocas vocales e incluso ninguna. Además, su duración es la más elevada entre ambas clases. Variables con valores bajos: danceability (0.46), speechiness (0.05), valence (0.36), energy (0.30) y baja loudness (-13.6). Estas características indican que no es música con alto BPM, y que tiende a ser tranquila e incluso melancólica.

Teniendo todo esto en cuenta, más la duración elevada, creemos que agrupó por pistas relacionadas a la música Clásica, la música ambiental, el Jazz suave o los instrumentales. En general, música donde se destaca el instrumento.

Cluster 1: Variables con valores altos: energy (0.72), loudness (-6.3), valence (0.55), danceability (0.65), speechiness (0.12) y tempo (123.8 BPM). Esto indica que son canciones más fuertes, rítmicas y alegres. Son bailables y poseen un BPM mayor. Variables con valores bajos: instrumentalness (0.04) y acousticness (0.19). Esto nos habla de tracks con poco instrumental y con menor acústica. El conjunto de estas características muestra tracks que poseen un alto BPM y se centran en los vocales. Tienden a tener un instrumental básico, electrónico y sencillo y pegadizo. Suelen ser rítmicas y alegres, movidas y bailables. Consideramos que en este grupo se juntan canciones de los géneros Pop, Hip Hop, Rap y Reggaetón.

Además, decidimos implementar unos gráficos de barra que ilustran perfectamente las diferencias de cada cluster respecto a cada variable. Estos permiten comprender la tabla de una forma más sencilla.





En conclusión, nos quedamos con $k=2$ como la cantidad óptima de clusters. Esta elección se basa en que ofrece una separación clara y coherente entre los grupos, lo cual resulta fundamental para la interpretación y el análisis de los datos. Los dos clusters identificados reflejan diferencias marcadas en los géneros musicales: el primer grupo (cluster 0) agrupa principalmente música Clásica, ambiental, Jazz suave e instrumentales, mientras que el segundo (cluster 1) incluye géneros como Pop, Hip Hop, Rap y Reggaetón. Esta división respalda la idea de que existen patrones diferenciables en el dataset según características musicales, y valida la elección de $k=2$ desde un enfoque métrico tanto como interpretativo.

Cuadro de tiempo dedicado

Integrante	Tarea	Prom. Hs Semana
Ramiro Barcala Roca	Armado de graficos entre distintos K Implementación del K-Means	4
Rafaela Pilar Arias	Análisis exploratorio de las variables Análisis de la tendencia al clustering Realización del informe	5
Mora Lema	Análisis de la tendencia al clustering Análisis Silhouette Realización del informe	5
Lara Eliana Ienco	Análisis de la tendencia al clustering Interpretación de Gráficos	3